

**ANALISIS KELAYAKAN MODEL *MACHINE LEARNING*
MENGUNAKAN DATASET WESAD UNTUK DETEKSI
ANXIETY: UPAYA SIMPLIFIKASI MODALITAS
MENGUNAKAN *WEARABLE* TUNGGAL**

PROPOSAL SKRIPSI

Disusun oleh:
Rizqy Jauhary Atsaany
NIM: 235150300111038



TEKNIK KOMPUTER
DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA
MALANG
2026

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR GAMBAR	iv
DAFTAR TABEL	v
DAFTAR LAMPIRAN	vi
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan	3
1.4 Manfaat	4
1.5 Batasan Masalah	4
1.6 Sistematika Pembahasan	5
BAB 2 LANDASAN KEPUSTAKAAN	6
2.1 <i>Anxiety</i>	6
2.1.1 <i>State Anxiety</i> (S-Anxiety)	6
2.1.2 <i>Trait Anxiety</i> (T-Anxiety)	6
2.2 <i>State-Trait Anxiety Inventory</i> (STAI)	6
2.2.1 Struktur Skala STAI	7
2.2.2 Sistem Penilaian STAI	7
2.2.3 Keandalan dan Validitas Instrumen STAI	7
2.3 Sinyal dan Biosinyal (Sinyal Fisiologis)	8
2.3.1 <i>Blood Volume Pulse</i> (BVP) dan <i>Photoplethysmography</i> (PPG)	8
2.3.2 Elektrokardiogram (EKG/ECG)	8
2.3.3 Aktivitas Elektrodermal (EDA)	9
2.3.4 Electromiogram (EMG)	9
2.3.5 Respirasi (Pernafasan)	9
2.3.6 Suhu Tubuh	9
2.3.7 Akselerasi Tiga Sumbu (<i>Accelerometer</i>)	10
2.4 <i>Wearables</i> dan <i>Smartwatch</i>	10
2.5 Pembelajaran Mesin (<i>Machine Learning</i>)	10

2.5.1 <i>Decision Tree</i> (DT)	10
2.5.2 <i>Random Forest</i> (RF)	11
2.5.3 Analisis Diskriminan Linear (LDA)	11
2.5.4 <i>K-Nearest Neighbor</i> (k-NN)	11
2.5.5 AdaBoost (AB)	11
2.5.6 <i>Support Vector Machine</i> (SVM)	11
2.5.7 XGBoost (XGB)	12
2.6 WESAD (<i>Wearable Stress and Affect Detection</i>)	12
2.7 Stroop Color-Word Test (SCWT)	12
BAB 3 METODOLOGI	14
3.1 Tipe dan Desain Penelitian	14
3.2 Alur Penelitian	14
3.3 Sumber Data dan Pengumpulan Data	18
3.3.1 Data Sekunder (Dataset WESAD)	18
3.3.2 Data Primer (Skenario Pengujian Dunia Nyata)	18
3.4 Pra-Pemrosesan Data dan Ekstraksi Fitur	19
3.4.1 Penyaringan Sinyal (<i>Filtering</i>)	19
3.4.2 Segmentasi Jendela Waktu (<i>Windowing</i>)	20
3.4.3 Ekstraksi Fitur	20
3.5 Pengembangan Model <i>Machine Learning</i>	21
3.5.1 Algoritma Model	21
3.5.2 Skema Validasi Model (<i>Cross-Validation</i>)	22
3.6 Implementasi Sistem pada Smartwatch (<i>Deployment</i>)	22
3.7 Metrik Pengujian dan Rencana Analisis Komparasi	22
3.7.1 Metrik Evaluasi	22
3.7.2 Rencana Komparasi Hasil	22
3.8 Lingkungan dan Peralatan Pendukung	23
3.8.1 Perangkat Keras (<i>Hardware</i>):	23
3.8.2 Perangkat Lunak (<i>Software</i>):	23
DAFTAR REFERENSI	24

DAFTAR GAMBAR

Gambar 3.1 Diagram Alur Proposal Penelitian	15
Gambar 3.2 Diagram Venn Kombinasi Sensor Skenario 1	16
Gambar 3.3 Diagram Venn Kombinasi Sensor Skenario 2	16
Gambar 3.4 Diagram Venn Kombinasi Sensor Skenario 3	17
Gambar 3.5 Diagram Venn Kombinasi Sensor Skenario 4	17
Gambar 3.6 Diagram Venn Kombinasi Sensor Skenario 5	18

DAFTAR TABEL

Tabel 3.1 Komparasi Skenario-Skenario Penelitian	23
--	----

DAFTAR LAMPIRAN

LAMPIRAN A PERSYARATA	
DAFTAR REFERENSI	24
LAMPIRAN A KUESIONER EVALUASI METRIK STAI	27
A.1 Kuesioner Evaluasi Diri STAI Form Y-1.....	27

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Perangkat yang dapat dikenakan (*wearables*) khususnya pada jam tangan pintar (*smartwatch*) komersial generasi terbaru telah berkembang dari sekadar pelacak kebugaran sederhana menjadi instrumen komputasi canggih yang dapat memonitor berbagai metrik kesehatan dengan dilengkapi berbagai sensor biofisiologis. Sensor-sensor tersebut dapat mencakup Aktivitas Elektrodermal (EDA), *Photoplethysmography* (PPG), Elektrokardiogram (ECG), suhu kulit tubuh, hingga *Bioelectrical Impedance Analysis* (BIA) (Gomes et al., 2023). Namun, ketersediaan sensor biofisiologis yang kaya ini belum diimbangi dengan pemanfaatan (*sensor utilization*) yang optimal pada ranah kesehatan mental. Hal ini dikarenakan *machine learning* relatif baru ketika digunakan pada konteks data fisiologis, dan hampir tidak ada studinya ketika berbicara soal monitoring kesehatan berbasis *wearables* (Gomes et al., 2023).

Di sisi lain, isu kesehatan mental seperti *anxiety* menjadi tantangan yang sangat perlu dipertimbangkan dalam kehidupan modern yang serba cepat karena dapat mengganggu kemampuan untuk berpikir dan konsentrasi (Vytal et al., 2012). Spielberger (1966) menentukan bahwa *anxiety* terbagi menjadi dua, yaitu *state anxiety* dan *trait anxiety*. *State anxiety* didefinisikan sebagai kondisi emosional sementara yang ditandai dengan perasaan tegang, ketakutan, dan peningkatan aktivitas sistem saraf otonom yang disadari; *State anxiety* inilah yang akan diteliti pada penelitian ini. Sementara *trait anxiety* didefinisikan sebagai sifat kepribadian seseorang yang merefleksikan seberapa cenderung individu tersebut merasakan *anxiety* di berbagai situasi. Sebagai salah satu pionir penelitian terkait *anxiety*, Spielberg membuat instrumen yang memvalidasi tingkatan *anxiety* dalam bentuk kuesioner yang dipublikasinya bernama *State-Trait Anxiety Inventory* (STAI). Instrumen ini masih menjadi standar dalam literatur saat ini dan digunakan juga oleh referensi utama studi penelitian ini.

Kemajuan teknologi sudah sampai pada titik dimana data dari sensor-sensor yang diperoleh dari perangkat *wearables* mampu menginferensi berbagai kondisi kesehatan mental pengguna. Penelitian yang dilakukan oleh Tayarani-N. dan Shahid (2025) mengonfirmasi potensi pemanfaatan sensor-sensor yang terdapat pada *wearables* saat ini layak digunakan untuk deteksi *anxiety* menggunakan *machine learning* (ML). Data fisiologis seperti EDA, ECG, hingga *Heart Rate Variability* (HRV) pada *smartwatch* menunjukkan potensi besar dalam pendeteksian *anxiety*. Sensor-sensor tersebut biasanya sudah ada di *smartwatch* pada umumnya, sehingga membuka peluang deteksi *anxiety* secara non-invasif (Tayarani-N. dan Shahid, 2025).

Di penelitian lain mengenai kesehatan mental, studi yang berjudul "*Introducing WESAD, a Multimodal Dataset for Wearable Stress and Affect Detection*" yang dilakukan oleh Schmidt et al. (2018) mempublikasikan dataset yang berisi rekaman data fisiologis. Penelitian Schmidt bertujuan untuk deteksi

stres dan afek (emosi) menggunakan 2 perangkat *wearables*, RespiBAN Professional yang dikenakan di dada dan Empatica E4 yang dikenakan di pergelangan tangan layaknya jam tangan. Meskipun tujuan studi ini adalah deteksi stres dan afek, dataset ini juga mencantumkan acuan kebenaran dalam format kuesioner STAI, dimana ini merupakan instrumen pengukuran *anxiety*.

Dataset *Wearables Stress and Affect Detection* (WESAD) ini kemudian digunakan dalam penelitian yang dilakukan oleh Alkurdi et al. (2025), yang secara mendalam melakukan analisis *transfer learning* pada model dataset WESAD untuk deteksi *anxiety* guna mengevaluasi potensi dan batasan dalam mengadaptasi model dari dataset sekunder ke skenario dunia nyata yang lebih bervariasi. Agar tujuan penelitian tersebut tercapai, Alkurdi et al. menggunakan model dari dataset WESAD untuk melakukan deteksi *anxiety* dengan pendekatan *Transfer Learning*, model tersebut kemudian dibandingkan dengan model ML yang dibangun menggunakan pendekatan tradisional. Model-model ini kemudian diuji dengan data baru sekunder dari dua studi lainnya, RADWear dan WEAR. Selain itu, penelitian ini juga menganalisis distribusi signifikansi fitur di berbagai sinyal fisiologis. Studi yang dilakukan oleh Alkurdi et al. inilah yang dijadikan referensi utama dalam pengambilan *research gap* penelitian ini.

Pemilihan dataset WESAD sebagai basis pelatihan model *machine learning* pada penelitian ini didasari oleh statusnya sebagai dataset sekunder terbuka yang dapat diakses secara bebas oleh komunitas ilmiah. Pemanfaatan dataset publik ini memungkinkan proses perancangan, pelatihan, dan validasi awal algoritma dilakukan secara terukur tanpa mengharuskan peneliti melakukan akuisisi data primer dalam jumlah masif sejak awal. Dengan mengandalkan data fisiologis terstandarisasi yang telah divalidasi oleh para peneliti sebelumnya, penelitian ini dapat memusatkan fokus pada analisis komparasi dan kelayakan simplifikasi sensor, sebelum akhirnya model hasil pelatihan diuji performanya secara langsung pada skenario pengujian terbatas di dunia nyata. Dari penelitian Alkurdi et al. (2025) tersebut, pendekatan *Transfer Learning* dari dataset WESAD ke skenario dunia nyata telah dieksplorasi dan menunjukkan hasil yang mengisyaratkan adanya potensi untuk dapat dikembangkan lebih lanjut, dengan rentang performa model terbaik di akurasi 76-93% dan *F1-Score* 0.76-0.94. Selain itu, hasil penelitian Alkurdi et al. juga menemukan bahwa membangun ML dari dataset WESAD dengan pendekatan tradisional menghasilkan akurasi dan *F1-score* yang memuaskan dengan nilai kedua metriknya di atas 90% dan 0.90. Angka tersebut menyimpulkan bahwa membangun model ML dari dataset WESAD memiliki potensi baik untuk mendeteksi *anxiety*.

Diambil dari potensi tersebut, skripsi ini menawarkan penelitian yang bertujuan untuk menganalisis kelayakan implementasi model yang dibangun dari dataset WESAD. Namun, alih-alih berfokus menggunakan *Transfer Learning* seperti yang dilakukan Alkurdi et al. (2025), penelitian ini membangun berbagai model ML dengan kombinasi sensor yang berbeda-beda yang kemudian akan dikomparasi. Hal ini dilakukan dalam upaya deteksi kondisi *anxiety* yang lebih baik ke dalam *smartwatch* tanpa perlu membangun data pelatihan primer dari

awal. Selain itu, skripsi ini juga berfokus pada upaya simplifikasi modalitas dengan membatasi akuisisi data hanya pada satu *wearable*, yaitu *smartwatch*, alih-alih mengikuti dataset WESAD yang menggunakan dua perangkat *wearables* pada pergelangan tangan dan dada.

Untuk pengujian dunia nyata yang akan dilakukan dalam penelitian ini, induksi *anxiety* dilakukan dengan menerapkan protokol uji yang sudah terbukti, yaitu *Stroop Color-Word Test* (SCWT) sebagai representasi stresor mental. Mengacu pada kajian literatur mengenai deteksi *anxiety* berbasis ML oleh He et al. (2025), stresor mental merupakan metode stimulasi eksperimental yang terbukti efektif dalam memicu *anxiety* pada subjek. Penerapan pengujian ini bertujuan untuk memastikan bahwa respon fisiologis yang direkam oleh sensor *smartwatch* benar-benar mencerminkan kondisi *state anxiety* yang valid dengan pengujian yang sudah terbukti, sebelum dievaluasi terhadap skor acuan kuesioner STAI. Sementara untuk sensor pengambilan data *smartwatch* yang akan digunakan adalah jam tangan pintar Galaxy Watch 9 milik Samsung.

1.2 Rumusan Masalah

- 1) Bagaimana kelayakan dan performa model *machine learning* yang dibangun dari dataset WESAD untuk mendeteksi kondisi *anxiety* tanpa mengandalkan data pelatihan primer?
- 2) Bagaimana perbandingan performa deteksi *anxiety* antara model yang memanfaatkan seluruh konfigurasi sensor *smartwatch* yang beririsan dengan dataset WESAD, dibandingkan dengan model yang telah direduksi ke kombinasi sensor minimum dengan signifikansi fitur tertinggi?
- 3) Apakah upaya simplifikasi akuisisi data dari penggunaan perangkat *wearable* ganda (dada dan pergelangan tangan) menjadi *wearable* tunggal berupa *smartwatch* komersial (Galaxy Watch 9) dapat mempertahankan performa deteksi yang memadai pada skenario dunia nyata?

1.3 Tujuan

- 1) Menganalisis kelayakan dan performa model *machine learning* yang dibangun dari dataset WESAD untuk mendeteksi kondisi *anxiety*, untuk membuktikan apakah model dapat bekerja dengan baik tanpa mengandalkan data pelatihan primer.
- 2) Membandingkan performa deteksi *anxiety* antara model yang menggunakan seluruh sensor *smartwatch* (yang beririsan dengan WESAD) dengan model hasil reduksi yang hanya menggunakan kombinasi sensor minimum berdasarkan tingkat signifikansi fiturnya.
- 3) Mengevaluasi efektivitas upaya simplifikasi perangkat dari penggunaan *wearables* ganda (dada dan pergelangan tangan) menjadi *wearable* tunggal (*smartwatch* komersial Galaxy Watch 9), untuk memastikan apakah simplifikasi tersebut masih mampu mempertahankan performa deteksi yang memadai saat diuji pada skenario dunia nyata.

1.4 Manfaat

Bagi Perkembangan Ilmu Pengetahuan (Akademisi dan Peneliti):

- Memberikan wawasan dan literatur baru terkait model ML yang dibangun dari dataset laboratorium (WESAD) menuju skenario dunia nyata untuk ranah kesehatan mental.
- Menyajikan bukti mengenai sejauh mana simplifikasi arsitektur model dan reduksi sensor (khususnya pembatasan pada ECG dan temperatur kulit) memengaruhi tingkat akurasi dalam mendeteksi *anxiety*.

Bagi Pengembang Teknologi dan Industri (Developer & Produsen *Smartwatch*):

- Menjadi landasan teknis yang solid bagi para pengembang perangkat lunak untuk merancang algoritma deteksi *anxiety* yang lebih efisien dan ringan, karena difokuskan pada sensor yang benar-benar memiliki signifikansi tinggi.
- Mendorong produsen *wearables* komersial untuk terus mengoptimalkan sensor-sensor fisiologis esensial pada satu perangkat pergelangan tangan, tanpa mengharuskan pengguna memakai alat medis tambahan yang kompleks.

Bagi Masyarakat Luas

- Menawarkan solusi pemantauan kesehatan mental yang jauh lebih praktis, nyaman, dan non-invasif dalam kehidupan sehari-hari, mengingat masyarakat modern hanya perlu mengenakan satu *smartwatch* layaknya aksesoris biasa.
- Meningkatkan kesadaran individu terhadap kondisi psikologis dan tingkat *anxiety* mereka sendiri secara *real-time*, sehingga dapat mengambil langkah preventif atau intervensi dini saat *anxiety* mulai terdeteksi.

1.5 Batasan Masalah

- Batasan Dataset: Pelatihan model ML hanya menggunakan data sekunder dari dataset publik WESAD, tanpa melakukan pengambilan data primer dari awal.
- Batasan Kondisi Psikologis: Klasifikasi deteksi yang dilakukan oleh model dibatasi hanya pada pendeteksian kondisi *anxiety*, khususnya *state anxiety*, berdasarkan parameter yang sejalan dengan instrumen STAI, dan tidak mencakup identifikasi gangguan mental atau kondisi emosional kompleks lainnya (seperti depresi).
- Batasan Modalitas dan Sensor: Evaluasi simplifikasi perangkat hanya difokuskan pada penggunaan *wearable* tunggal di pergelangan tangan. Sensor-sensor dari dataset WESAD yang tidak terdapat pada *smartwatch* yang akan digunakan tidak diikutsertakan pada model akhir. Reduksi fitur

dilakukan dengan menggunakan paling minimal satu sensor dengan berbagai fitur yang diekstraksi.

- Batasan Skenario Pengujian: Pengujian kelayakan model di dunia nyata dibatasi pada pengambilan data di laboratorium terkontrol yang telah ditentukan secara spesifik dan terbukti secara literatur mampu memicu *anxiety* (*Stroop Color-Word Test*), bukan pemantauan secara terus-menerus dalam jangka waktu yang panjang.

1.6 Sistematika Pembahasan

- BAB I PENDAHULUAN

Bab ini merupakan penjelasan awal yang menguraikan kerangka dasar urgensi penelitian. Bab ini berisi latar belakang masalah yang menjelaskan transisi pendeteksian *anxiety* menuju pemanfaatan *wearable* tunggal, rumusan masalah, tujuan penelitian, manfaat penelitian bagi berbagai pihak, batasan masalah untuk menjaga fokus penelitian, serta sistematika pembahasan itu sendiri.

- BAB II TINJAUAN PUSTAKA

Bab ini menjabarkan fondasi teori dan penelitian terdahulu yang mendukung jalannya skripsi. Pembahasan difokuskan pada literatur terkait konsep *anxiety* dan instrumen STAI, karakteristik dataset WESAD, pemanfaatan sensor fisiologis (EDA, ECG, temperatur, dsb.) pada *smartwatch*, tinjauan mengenai konsep pembangunan model *machine learning* yang menjadi metode utama dalam penelitian, hingga *ground truth* yang menjelaskan bagaimana validasi pengujian dunia nyata yang akan dilakukan.

- BAB III METODOLOGI PENELITIAN

Bab ini bertindak sebagai penutup proposal yang menguraikan langkah-langkah teknis dan sistematis dalam menyelesaikan rumusan masalah. Bagian ini mencakup alur penelitian, skenario pengumpulan data sekunder dan data uji dunia nyata, tahapan pemrosesan data, desain arsitektur model ML berbasis fitur, proses komparasi performa antar konfigurasi kombinasi sensor, hingga metrik evaluasi yang digunakan untuk mengukur keberhasilan model.

BAB 2 LANDASAN KEPUSTAKAAN

2.1 Anxiety

Anxiety didefinisikan sebagai respon alami tubuh terhadap stres atau ancaman. *Anxiety* dicirikan dengan perasaan cemas, tidak nyaman, atau ketakutan terhadap sesuatu yang akan terjadi dan biasanya diasosiasikan dengan refleksi fisik termasuk peningkatan detak jantung, ketegangan otot, gelisah, dsb. (Kessler et al., 2005; Carter et al., 2001, dikutip dari Tayarani-N dan Shahid, 2025). *Anxiety* memiliki dua bentuk, yaitu *state* dan *trait anxiety*. *State anxiety* didefinisikan sebagai kondisi sementara yang ter-influensi oleh situasi saat itu dimana responden menyadari bagaimana perasaannya pada saat itu juga. Sementara *trait anxiety* merupakan sifat kepribadian seseorang yang merefleksikan kecenderungan individu tersebut merasakan *anxiety* di berbagai situasi (Spielberger, 1966).

2.1.1 State Anxiety (S-Anxiety)

State anxiety adalah kondisi emosional sementara pada diri individu yang terjadi pada momen tertentu dengan intensitas tertentu. Kondisi ini ditandai oleh perasaan subjektif yang disadari seperti ketegangan (*tension*), kekhawatiran (*worry*), kegelisahan (*nervousness*), dan ketakutan (*apprehension*), yang disertai dengan pengaktifan atau rangsangan sistem saraf otonom. Intensitas S-Anxiety berfluktuasi sepanjang waktu bergantung pada tingkat stres psikologis atau ancaman situasi yang dihadapi (Spielberger, 1966). *Anxiety* dalam bentuk ini yang diteliti skripsi ini untuk dilakukan upaya deteksi kondisi *anxiety*.

2.1.2 Trait Anxiety (T-Anxiety)

Trait anxiety adalah dinamika pada tiap individual dalam kecenderungan untuk terkena *anxiety*. Hal ini merujuk pada disposisi kepribadian seseorang dalam memandang dan merespons situasi lingkungan; individu dengan nilai T-Anxiety tinggi memiliki kecenderungan lebih besar untuk mempersepsikan berbagai macam situasi sebagai situasi yang berbahaya atau mengancam, serta cenderung merespons situasi tersebut dengan peningkatan intensitas *State Anxiety* yang lebih tinggi dibandingkan individu dengan T-Anxiety rendah (Spielberger, 1966).

2.2 State-Trait Anxiety Inventory (STAI)

State-Trait Anxiety Inventory (STAI) dikembangkan oleh Charles D. Spielberger bekerja sama dengan R.L. Gorsuch, R. Lushene, P.R. Vagg, dan G.A. Jacobs untuk mengukur kedua aspek *anxiety* secara mandiri (*self-evaluation questionnaire*). Kuesioner ini dibuat pada awal tahun 1964 dan terus mengalami perubahan mulai dari revisi edisi "STAI Form X" hingga edisi yang terbarunya "STAI Form Y" yang menjadi bentuk revisi standar yang umum digunakan saat ini (Spielberger et al., 1983). Pertanyaan-pertanyaan kuesioner ini dapat dilihat pada lampiran.

2.2.1 Struktur Skala STAI

Instrumen STAI terdiri dari 40 butir pernyataan yang terbagi ke dalam dua skala terpisah:

- Skala S-Anxiety (Form Y-1)

Terdiri dari 20 butir yang mengevaluasi perasaan responden pada saat ini atau momen sekarang. Skala ini menggunakan respons 4-poin skala intensitas: (1) Tidak sama sekali (*Not at all*), (2) Sedikit (*Somewhat*), (3) Sedang (*Moderately so*), (4) Sangat benar begitu (*Very much so*). Form varian ini yang akan digunakan untuk validasi pengujian dunia nyata penelitian ini.

- Skala T-Anxiety (Form Y-2)

Terdiri dari 20 butir yang mengevaluasi bagaimana responden pada biasanya atau umumnya merasa. Skala ini menggunakan respons 4-poin skala frekuensi: (1) Hampir tidak pernah (*Almost never*), (2) Terkadang (*Sometimes*), (3) Sering (*Often*), (4) Hampir selalu (*Almost always*).

2.2.2 Sistem Penilaian STAI

Setiap skala menghasilkan skor total berkisar antara 20 hingga 80.

- Item Positif (*Anxiety-Present*)

Item yang mengindikasikan kehadiran kecemasan (misal: "saya merasa tegang", "saya merasa khawatir") diberi skor langsung sesuai bobot respons 1 hingga 4.

- Item Terbalik (*Anxiety-Absent*)

Butir yang mengindikasikan ketiadaan kecemasan atau ketenangan (misal: "saya merasa tenang", "saya merasa rileks") dinilai terbalik (*reverse scoring*), di mana respons 1, 2, 3, 4 diubah nilainya menjadi 4, 3, 2, 1.

2.2.3 Keandalan dan Validitas Instrumen STAI

- Reliabilitas Konsistensi Internal

Kedua skala STAI memiliki konsistensi internal yang sangat tinggi. Koefisien *Cronbach's Alpha* untuk Form Y pada sampel normatif dewasa, mahasiswa, dan rekrut militer umumnya berada di atas 0.90 (median $\alpha = 0.93$ untuk S-Anxiety dan $\alpha = 0.90$ untuk T-Anxiety) (Spielberger et al., 1983).

- Stabilitas (*Test-Retest*)

Koefisien reliabilitas tes-ulang untuk skala T-Anxiety terbukti stabil dalam berbagai rentang waktu (berkisar antara 0.65 hingga 0.86), membuktikan sifatnya sebagai *trait* kepribadian yang menetap. Sebaliknya, koefisien stabilitas untuk skala S-Anxiety relatif rendah

(median $r \approx 0.33$), yang mana hal ini diharapkan karena S-Anxiety dirancang sensitif terhadap fluktuasi kondisi psikologis dan stres situasional (Spielberger et al., 1983).

- Validitas Konstruksi dan Konkuren

Skala T-Anxiety berkorelasi tinggi dengan instrumen kecemasan terkemuka lainnya (seperti *Taylor Manifest Anxiety Scale* dan *IPAT Anxiety Scale*). Skala S-Anxiety terbukti secara empiris mengalami peningkatan signifikan pada situasi yang sarat stres (seperti sebelum ujian atau prosedur medis) dan mengalami penurunan signifikan setelah sesi relaksasi (Spielberger et al., 1983).

2.3 Sinyal dan Biosinyal (Sinyal Fisiologis)

Biosinyal atau sinyal fisiologis didefinisikan sebagai "pembacaan multisaluran yang dikumpulkan dari sistem saraf pusat dan otonom" (Khullar et al., 2022, disitasi dari Tayarani-N dan Shahid, 2025). Sinyal-sinyal ini umumnya membawa informasi signifikan mengenai kondisi internal seseorang (Tayarani-N dan Shahid, 2025). Ada banyak sinyal fisiologis yang berkaitan dengan *anxiety* pada seseorang. Namun, pada dataset WESAD dan penelitian yang akan dilakukan ini, sinyal-sinyal yang digunakan termasuk: biosinyal *Blood Volume Pulse* (BVP), Elektrokardiogram (ECG), Aktivitas Elektrodermal (EDA), Electromiogram (EMG), Respirasi, Suhu Tubuh, dan juga sinyal akselerasi tiga sumbu (Schmidt et al., 2018).

2.3.1 *Blood Volume Pulse* (BVP) dan *Photoplethysmography* (PPG)

Blood Volume Pulse (BVP) diukur menggunakan teknik optik yang dinamakan *Photoplethysmography* (PPG) untuk mendeteksi variasi volume pada sirkulasi darah tepi di permukaan kulit. Teknik ini sering digunakan secara non-invasif untuk melakukan pengukuran di permukaan kulit (Allen, 2007). Studi Yu dan Gan (2022, disitasi dari Tayarani-N dan Shahid, 2025) menunjukkan bahwa sinyal BVP pada jari dapat membawa informasi mengenai tingkat *anxiety* pada seseorang.

2.3.2 Elektrokardiogram (EKG/ECG)

Tes elektrokardiogram (EKG/ECG) adalah tes sederhana yang merekam sinyal listrik yang dihasilkan jantung pada saat berdetak menggunakan teknik optik. Sinyal-sinyal ini memberitahu keempat bilik jantung untuk berkontraksi dalam ritme tertentu yang dibutuhkan jantung untuk memompa darah ke seluruh tubuh (National Library of Medicine, 2026). Sinyal ECG umumnya diekstraksi menjadi fitur HRV bersamaan dengan sinyal PPG untuk berbagai tujuan, salah satunya adalah untuk mendeteksi *anxiety*. Berdasarkan dari beberapa studi yang diteliti oleh Tayarani-N dan Shahid (2025), ECG menangkap aktivitas kelistrikan jantung yang berkorelasi kuat dengan gairah emosional akibat stres atau *anxiety*. Saat tubuh mengalami stres, sistem saraf simpatik melepaskan hormon yang meningkatkan detak jantung sebagai persiapan respons fisik "*fight-or-flight*" (Schmidt et al., 2018).

2.3.3 Aktivitas Elektrodermal (EDA)

Aktivitas Elektrodermal (*Electrodermal Activity* / EDA) adalah fenomena kelistrikan apapun yang terjadi pada kulit. Konduktansi kulit, suatu pengukuran dari EDA, menunjukkan fluktuasi yang dikarenakan oleh aktivasi Sistem Saraf Otonom (*Autonomic Nervous System* / ANS) yang menginduksi sekresi keringat. Karena ini, EDA mampu menangkap informasi psikofisiologis yang dapat digunakan dalam penelitian mengenai kesehatan mental dan fisiologis (Amin dan Faghih, 2022).

2.3.3.1 Konduktansi Kulit

Konduktansi kulit merupakan tingkatan seberapa konduktif kulit terhadap listrik. Hal ini dapat diukur melalui sensor dengan memberikan sedikit tegangan ke kulit. Efek dari *anxiety* juga dapat diamati melalui respon otot atau aktivitas kelistrikan dalam menanggapi stimulus saraf. Ini dikarenakan aktivitas otak yang abnormal dapat mengontraksi otot sehingga mengeluarkan aktivitas listrik pada kulit (Tayarani-N dan Shahid, 2025). Studi yang dilakukan oleh Desai et al. (2022, disitasi dari Tayarani-N dan Shahid, 2025) menunjukkan bahwa sinyal konduktansi kulit ini dapat digunakan untuk mengidentifikasi *anxiety*, selama akurasi dan kalibrasi dari sensor yang digunakan mumpuni.

2.3.4 Electromiogram (EMG)

Elektromiografi atau elektromiogram (*Electromyogram* / EMG) adalah prosedur pemeriksaan untuk mengukur atau merekam aktivitas listrik otot dan saraf yang mengontrolnya. Pemeriksaan ini dapat memantau aktivitas pada otot, saraf, atau keduanya. Elektromiografi dilakukan dengan menggunakan alat pendeteksi aktivitas listrik otot, yaitu elektroda, yang terhubung dengan mesin EMG. Dengan alat tersebut, aktivitas listrik otot dapat diamati (Alodokter, 2024). Pengukuran tingkat *anxiety* menggunakan EMG telah berhasil dicapai, di samping teknik-teknik pengukuran sensor sinyal fisiologis lainnya (Muhammad dan Al-Ahmadi, 2022).

2.3.5 Respirasi (Pernafasan)

Sinyal fisiologis Respirasi atau Pernafasan merupakan sinyal yang mencakup keseluruhan informasi pernafasan. Sinyal pernafasan, seperti interval nafas-pernafas, variabilitas kecepatan nafas, dsb. digunakan pada penelitian Haritha et al., (2017) untuk mendeteksi *anxiety*.

2.3.6 Suhu Tubuh

Suhu tubuh (temperatur tubuh/kulit) adalah ukuran dari kemampuan tubuh dalam menghasilkan dan menyingkirkan hawa panas. Suhu tubuh bisa dipengaruhi oleh berbagai hal, misalnya suhu lingkungan. Tinggi atau rendahnya suhu tubuh seseorang juga bisa mencerminkan kondisi kesehatannya. Suhu tubuh normal seseorang bisa berubah-ubah tergantung aktivitas yang dilakukan dan kondisi tubuhnya (Alodokter, 2026). Pada penelitian mengenai *anxiety* sosial oleh Shaukat-Jali et al. (2021), suhu kulit digunakan sebagai data untuk model

pendeteksian *anxiety* karena respon seseorang yang sedang terserang *anxiety* (dalam kasus ini sosial) dapat mengakibatkan variasi pada suhu kulit (umumnya suhu akan menurun).

2.3.7 Akselerasi Tiga Sumbu (*Accelerometer*)

Selain sinyal fisiologis, digunakan juga sinyal tradisional menggunakan sensor *accelerometer*. Sinyal ini digunakan karena seseorang yang terkena serangan *anxiety* dapat mengalami gemetaran (*trembling*) pada diri mereka (Shaukat-Jali et al., 2021). Hal ini diperkuat oleh penelitian McGinnis et al. (2018) yang menggunakan data gerakan *accelerometer* dan *gyroscope* untuk memprediksi tingkat *anxiety* pada partisipannya dengan hasil akurasi yang cukup tinggi.

2.4 *Wearables* dan *Smartwatch*

Perangkat komputasi *mobile* yang dikenakan pada tubuh (*wearable devices*), khususnya jam tangan pintar (*smartwatch*) yang dikenakan pada pergelangan tangan, telah berkembang pesat. *Smartwatch* komersial saat ini sudah mampu menjadi instrumen pemantauan kesehatan digital yang mampu merekam parameter fisiologis manusia secara non-invasif, kontinu, dan real-time (Gedam and Paul, 2021). Dalam ranah *machine learning* pada *wearables*, integrasi sensor biosinyal pada *smartwatch* membuka peluang untuk mendeteksi respons sistem saraf otonom (ANS) terhadap pemicu stres psikologis maupun *anxiety* dalam aktivitas sehari-hari tanpa mengganggu mobilitas pengguna (Tayarani-N dan Shahid. 2025).

2.5 Pembelajaran Mesin (*Machine Learning*)

Pembelajaran mesin (*Machine Learning* / ML) merupakan cabang dari kecerdasan buatan (*Artificial Intelligence* / AI) yang berfokus pada pengembangan algoritma dan teknik agar sistem komputer dapat belajar secara mandiri dari data tanpa perlu diprogram secara eksplisit. Sistem ini memanfaatkan data historis untuk mengenali pola, mengekstrak pengetahuan, dan melakukan prediksi atau pengambilan keputusan secara otomatis (Goodfellow et al., 2016). Pada penelitian yang dilakukan oleh Schmidt et al. (2018) (patokan referensi penelitian ini), algoritma-algoritma ML yang digunakannya adalah model-model berbasis fitur berupa *Decision Tree* (DT), *Random Forest* (RF), *Linear Discriminant Analysis* (LDA), *k-nearest neighbor* (KNN), *Adaboost* (AB), *Support Vector Machine* (SVM), dan *XG Boost* (XGB).

2.5.1 *Decision Tree* (DT)

Decision Tree atau Pohon Keputusan adalah algoritma *machine learning* berbasis *supervised learning* (pembelajaran terawasi) yang memecah data secara hierarkis menjadi subset-subset yang lebih kecil berdasarkan aturan keputusan (kondisi) tertentu. Algoritma ini memvisualisasikan keputusan dalam bentuk struktur menyerupai pohon, di mana setiap node internal mewakili fitur/atribut,

cabang mewakili aturan keputusan, dan *leaf node* (daun) mewakili kelas keluaran atau hasil akhir (Wikipedia, 2026).

2.5.2 Random Forest (RF)

Random Forest adalah algoritma *ensemble learning* yang beroperasi dengan membangun banyak *Decision Tree* pada saat fase pelatihan. Untuk tugas klasifikasi, hasil akhir dari *Random Forest* ditentukan melalui mekanisme voting terbanyak (modus) dari prediksi masing-masing pohon individu. Pendekatan ini secara signifikan mengurangi risiko *overfitting* yang sering terjadi pada *decision tree* tunggal (Wikipedia, 2026).

2.5.3 Analisis Diskriminan Linear (LDA)

Analisis Diskriminan Linear (*Linear Discriminant Analysis* / LDA) adalah teknik statistik dan *machine learning* yang digunakan untuk menemukan kombinasi linear dari fitur-fitur yang paling baik dalam memisahkan dua atau lebih kelas objek. Analisis Diskriminan Linear (LDA), Analisis Diskriminan Normal (NDA), *Canonical Variates Analysis* (CVA), atau Analisis Diskriminan Fungsi adalah generalisasi dari Diskriminan Linear Fisher, metode yang digunakan di statistika dan bidang lain untuk menemukan kombinasi linear fitur yang mencirikan atau membedakan dua atau lebih kelas objek. LDA bekerja dengan memaksimalkan jarak antar rata-rata (mean) kelas sambil meminimalkan varians (penyebaran data) di dalam masing-masing kelas tersebut (Wikipedia, 2026).

2.5.4 K-Nearest Neighbor (k-NN)

K-Nearest Neighbor (k-NN / KNN) adalah algoritma *supervised learning* non-parametrik yang tergolong dalam metode di mana algoritma menunda proses generalisasi atau pembuatan model hingga ada kueri atau data pengujian yang masuk (*lazy learning*). Algoritma ini mengklasifikasikan titik data baru berdasarkan mayoritas label dari k titik data tetangga terdekatnya di ruang fitur. Jarak antar titik biasanya diukur menggunakan metrik seperti jarak Euclidean (Wikipedia, 2026).

2.5.5 AdaBoost (AB)

Adaptive Boosting atau AdaBoost (AB) adalah teknik *ensemble learning* yang menggabungkan beberapa "pengklasifikasi lemah" (*weak classifiers*), biasanya *decision tree* yang sangat dangkal, untuk membentuk satu "pengklasifikasi kuat" (*strong classifier*). Algoritma ini bekerja secara iteratif dengan memberikan bobot lebih besar pada sampel data yang salah diklasifikasikan sebelumnya, sehingga model berikutnya akan lebih fokus pada kasus-kasus yang sulit diprediksi tersebut (Wikipedia, 2026).

2.5.6 Support Vector Machine (SVM)

Support Vector Machine (SVM) adalah algoritma *supervised learning* yang bekerja dengan mencari *hyperplane* (bidang batas) optimal di dalam ruang N-dimensi. *Hyperplane* ini dirancang untuk memisahkan titik-titik data dari kelas

yang berbeda dengan margin (jarak) yang paling maksimal. Selain melakukan klasifikasi linear, SVM dapat secara efisien melakukan klasifikasi non-linier menggunakan trik kernel (*kernel trick*), merepresentasikan data hanya melalui serangkaian perbandingan kesamaan berpasangan antara titik data asli menggunakan fungsi kernel, sehingga mengubahnya menjadi koordinat dalam ruang fitur berdimensi lebih tinggi. Dengan demikian, SVM menggunakan trik kernel untuk secara implisit memetakan inputnya ke ruang fitur berdimensi tinggi, di mana klasifikasi linier dapat dilakukan (Wikipedia, 2026).

2.5.7 XGBoost (XGB)

XGBoost (*eXtreme Gradient Boosting*) adalah pustaka perangkat lunak sumber terbuka yang menerapkan kerangka kerja *decision tree* berbasis *gradient boosting* secara teratur (*regularizing*), skalabel, dan efisien. Cara kerjanya didasarkan pada metode penambahan pohon secara iteratif untuk mengoreksi kesalahan prediksi dari pohon-pohon sebelumnya menggunakan pendekatan Newton–Raphson di ruang fungsi; algoritma ini menghitung gradien tingkat pertama dan kedua (Hessian) dari fungsi kerugian (*loss function*), lalu melatih model lemah (*weak learner*) baru untuk meminimalkan aproksimasi Taylor tingkat kedua tersebut dengan tambahan parameter penalti regularisasi guna mencegah *overfitting* (Wikipedia, 2026).

2.6 WESAD (*Wearable Stress and Affect Detection*)

Dataset *Wearable Stress and Affect Detection* (WESAD) merupakan dataset multimodal publikasi Schmidt et al. (2018) yang dirancang untuk mendeteksi stres dan pengenalan kondisi afektif berbasis perangkat *wearable*. Dataset ini berisi data fisiologis dan data pergerakan yang direkam dari 15 subjek selama studi laboratorium. Perekaman data dilakukan menggunakan dua jenis penempatan perangkat yang berbeda, yaitu di dada dan di pergelangan tangan. WESAD menjembatani kesenjangan dari studi-studi pengenalan emosi sebelumnya dengan merangkum tiga keadaan afektif yang berbeda secara bersamaan, yaitu: kondisi netral, stres, dan hiburan/kesenangan. Meskipun WESAD bertujuan untuk deteksi stres dan pengenalan kondisi afektif, dataset ini juga mencantumkan acuan kebenaran untuk data tersebut berupa kuesioner STAI yang dipersingkat dan beberapa kuesioner psikometri laporan mandiri lainnya, sehingga dapat digunakan untuk pelatihan model ML baru yang bertujuan untuk mengklasifikasi *anxiety* (Schmidt et al., 2018).

2.7 Stroop Color-Word Test (SCWT)

Stroop Color-Word Test (SCWT) merupakan tes neuropsikologis yang pertama kali diperkenalkan oleh J. Ridley Stroop (1935) untuk mengevaluasi konflik kognitif dan kapasitas pemrosesan perhatian. Pada pengujian ini, partisipan diminta menyebutkan warna tinta dari kata yang ditampilkan, di mana arti kata dan warna tinta dapat saling bertentangan (misalnya kata "MERAH" yang ditulis dengan tinta berwarna biru).

Dalam studi eksperimental mengenai deteksi kecemasan, induksi *state anxiety* diperlukan untuk merangsang timbulnya respon fisiologis otonom pada uji terkontrol dunia nyata. Terdapat berbagai kategori stresor yang dapat menginduksi *anxiety*, mulai dari stresor sosial, mental, hingga stresor dari kehidupan sehari-hari. SCWT merupakan kategori stresor mental, tes ini menginduksi *anxiety* karena konflik perbedaan di antara arti kata dan warna kata tersebut membuat interferensi kognitif karena kondisi yang inkongruen, memaksa otak untuk meredam respon otomatis sehingga menciptakan mental *overload* yang memicu stres mental akut dan ketegangan fisiologis secara cepat (He et al., 2025).

BAB 3 METODOLOGI


Evaluasi kelayakan model ML dilakukan secara komparatif di berbagai konfigurasi modalitas sensor, mulai dari menggunakan keseluruhan sensor yang terdapat pada dataset WESAD, pemanfaatan seluruh sensor *smartwatch* yang beririsan dengan WESAD, hingga reduksi ke kombinasi sensor paling minimal yang terbukti memiliki signifikansi fitur tertinggi pada penelitian Alkurdi et al. (2025).

3.1 Tipe dan Desain Penelitian

Melalui eksperimen komputasi dan uji empiris kuantitatif, studi ini membandingkan berbagai konfigurasi kombinasi modalitas model ML untuk menentukan akurasi dan kelayakan model dalam mendeteksi *anxiety*. Desain ini dipilih karena tujuan utama penelitian adalah mengukur secara objektif dampak degradasi atau perubahan akurasi yang terjadi ketika modalitas sensor direduksi secara bertahap, dari *full multimodal laboratory* setup ke sensor *smartwatch*, hingga ke sensor minimalis fitur paling signifikan, serta saat model diuji pada dunia nyata. Melalui kontrol variabel konfigurasi sensor dan skenario pengujian, tingkat kelayakan simplifikasi perangkat dapat dijustifikasi secara empiris.

3.2 Alur Penelitian

Alur pelaksanaan penelitian dirancang secara sistematis melalui tahapan-tahapan yang saling berkesinambungan seperti yang disajikan pada diagram alir berikut:




Gambar 3.1 Diagram Alur Proposal Penelitian

Secara garis besar, tujuan penelitian ini mengevaluasi 5 skenario komparasi performa model:

- **Skenario 1 (Model *Baseline* WESAD – Referensi Paling Optimal):**


Membangun model menggunakan seluruh modalitas sensor yang ada pada dataset WESAD (sensor dada: ECG, EDA, EMG, Respirasi, Suhu, Akselerometer; serta sensor pergelangan: BVP, EDA, Suhu, Akselerometer). Skenario ini bertindak sebagai standar acuan tertinggi. Model ini merepresentasikan batas kemampuan optimal model ketika didukung oleh instrumen laboratorium multimodal ganda yang lengkap.



Gambar 3.2 Diagram Venn Kombinasi Sensor Skenario 1

- **Skenario 2 (Model Irisan Sensor Smartwatch – Model Data WESAD):**


Membangun model hanya dengan mengambil fitur dari sinyal sensor yang terdapat pada *smartwatch* komersial (irisan antara ketersediaan sensor pergelangan tangan WESAD dan spesifikasi *smartwatch*, yaitu umumnya EDA, BVP/PPG, Suhu Kulit, dan Akselerometer). Hal ini dilakukan untuk mengukur degradasi performa yang diakibatkan oleh reduksi modalitas (menghilangkan sensor dada) pada dataset yang sama, sebelum faktor lingkungan luar diikutsertakan.



Gambar 3.3 Diagram Venn Kombinasi Sensor Skenario 2

- **Skenario 3 (Model Sensor Minimalis Signifikan - Model Data WESAD):**


Membangun model hanya menggunakan sensor dengan signifikansi fitur tertinggi berdasarkan temuan penelitian referensi (Alkurdi et al., 2025). Skenario ini dilakukan untuk mengetahui batas efisiensi model paling efisien, mengingat *wearables* memiliki sumber daya yang sangat terbatas.



Gambar 3.4 Diagram Venn Kombinasi Sensor Skenario 3

- **Skenario 4 (Uji Dunia Nyata - Model Irisan Sensor *Smartwatch*):**


Model dari Skenario 2 diintegrasikan ke dalam ekosistem *smartwatch* dan diuji secara langsung pada subjek dalam kondisi *baseline* dan pada saat terinduksi *anxiety*. Skenario ini adalah tujuan utama dilakukannya penelitian ini, dimana model akan langsung diuji untuk menentukan layak atau tidaknya WESAD digunakan untuk deteksi *anxiety*. Selain itu, skenario ini menguji ketahanan dan kemampuan generalisasi model saat menghadapi *noise* dan variasi fisiologis dinamis yang terdapat di dunia nyata, alih-alih dalam eksperimen laboratorium terkontrol.



Gambar 3.5 Diagram Venn Kombinasi Sensor Skenario 4

- **Skenario 5 (Uji Dunia Nyata - Model Sensor Minimalis Menggunakan Fitur Paling Signifikan):**

Model dari Skenario 3 diuji langsung pada skenario dunia nyata yang sama dengan Skenario 4. Skenario ini dilakukan untuk memvalidasi apakah model minimalis tetap andal mendeteksi *anxiety* pada kondisi nyata tanpa memerlukan sensor pendukung lainnya.



Gambar 3.6 Diagram Venn Kombinasi Sensor Skenario 5

3.3 Sumber Data dan Pengumpulan Data

Penelitian ini menggunakan dua sumber data: data sekunder untuk pelatihan/pengujian awal model dan data primer untuk pengujian implementasi dunia nyata.

3.3.1 Data Sekunder (Dataset WESAD)

Data sekunder diperoleh dari dataset publik WESAD (Wearable Stress and Affect Detection) yang dipublikasikan oleh Schmidt et al. (2018). Dataset ini terdiri dari rekaman fisiologis 15 subjek terstandarisasi dengan dua perangkat: RespiBAN (dada) pada frekuensi 700 Hz dan Empatica E4 (pergelangan tangan) dengan frekuensi bervariasi (BVP: 64 Hz, EDA: 4 Hz, Suhu: 4 Hz, ACC: 32 Hz).

3.3.2 Data Primer (Skenario Pengujian Dunia Nyata)

Data primer dikumpulkan secara langsung untuk keperluan pengujian performa model pada Skenario 4 (seluruh irisan sensor *smartwatch*) dan Skenario 5 (sensor minimalis ECG dan temperatur kulit) di lingkungan nyata.

3.3.2.1 Subjek Penelitian:

Subjek penelitian terdiri dari partisipan sukarelawan (mahasiswa usia 18–24 tahun) dalam kondisi fisik sehat, tidak memiliki riwayat penyakit kardiovaskular akut, dan tidak buta warna. Alasan pemilihan partisipan dalam rentang umur tersebut dikarenakan kelompok usia mahasiswa dewasa muda memiliki rentang responsivitas otonom yang dinamis serta representatif terhadap target pengguna *smartwatch* komersial untuk pemantauan kesehatan mental dan kebugaran harian. Selain itu, alasan mengambil subjek yang tidak mengalami kelainan buta warna dikarenakan pengujian SCWT yang mengharuskan partisipannya untuk mampu membedakan semua spektrum warna.

3.3.2.2 Protokol dan Skenario Pengujian:

Pengumpulan data primer dilakukan dalam suatu rangkaian eksperimen terstruktur yang membandingkan kondisi rileks (*baseline*) dengan kondisi

terinduksi kecemasan (*anxiety-induced*). Skenario induksi kecemasan mengadopsi taksonomi stresor dari studi Schmidt et al. (2018) yang diadaptasi, yaitu:

1. Fase Tenang / Pengukuran *Baseline*

Partisipan berada dalam ruangan tenang dengan posisi duduk rileks selama 5-10 menit tanpa gangguan distraksi visual maupun audio. Pada tahap ini, sensor *smartwatch* merekam sinyal biosinyal dalam keadaan normal. Perekaman fase dasar (*baseline*) diperlukan sebagai acuan kalibrasi fisiologis individual, mengingat nilai absolut sinyal fisiologis berbeda pada tiap individu.

2. Fase Stresor Mental: *Stroop Color-Word Test* (SCWT)

Partisipan diberikan tugas tes Stroop terkomputerisasi selama 5–10 menit dengan batas waktu cepat. Kesalahan dalam menjawab akan memberikan indikator visual dan/atau suara peringatan agar *anxiety* partisipan lebih terinduksi.

3.3.2.3 Instrumen Validasi (*Ground Truth*):

Untuk menetapkan label kebenaran pada data primer, partisipan mengisi kuesioner *State-Trait Anxiety Inventory* (STAI Form Y-1) pada dua titik waktu:

1. Setelah menyelesaikan Fase Tenang (*Baseline*).
2. Tepat setelah menyelesaikan rangkaian induksi kecemasan (SCWT dan TSST).

3.4 Pra-Pemrosesan Data dan Ekstraksi Fitur

Sinyal biofisiologis mentah rentan terhadap derau (*noise*) frekuensi tinggi dan *baseline wander*. Tahapan pra-pemrosesan meliputi:

3.4.1 Penyaringan Sinyal (*Filtering*)

- Sinyal EDA: Diberikan filter *low-pass* dengan frekuensi batas 1 Hz untuk menghilangkan derau akibat pergerakan kecil, kemudian didekomposisi menjadi komponen tonik (*Skin Conductance Level* / SCL) dan fasik (*Skin Conductance Response* / SCR).
- Sinyal ECG / BVP (PPG): Sinyal disaring menggunakan *band-pass filter* (0.5 – 40 Hz) untuk menghilangkan interferensi listrik dan pergerakan, dilanjutkan dengan algoritma deteksi puncak gelombang R (untuk ECG) atau puncak sistolik (untuk PPG/BVP) guna menghitung interval antar detakan (RR-interval).
- Sinyal Suhu & Akselerometer: Dilakukan *smoothing* menggunakan *moving average filter*.

3.4.2 Segmentasi Jendela Waktu (*Windowing*)

Data sinyal sensor secara umum akan dipotong menggunakan teknik *fixed sliding window* berdurasi 60 detik dengan pergeseran jendela 0.25 detik. Durasi jendela 60 detik ini merupakan standar yang terbukti efektif pada penelitian WESAD (Schmidt et al., 2018) dan Alkurdi et al. (2025). Namun, untuk sinyal sensor akselerometer, panjang *window* yang digunakan adalah 5, sesuai dengan dataset WESAD karena panjang *window* sekitaran tersebut lebih sering digunakan pada pengenalan konteks berbasis akselerasi (Reiss et al., 2012, disitasi dari Schmidt et al. 2018)

3.4.3 Ekstraksi Fitur

Dari setiap jendela waktu, fitur-fitur yang diekstraksi pada setiap sinyal adalah sebagai berikut:

- Akselerometer:
 - Mean, STD untuk tiap aksis.
 - Mean, STD jumlah semua aksis.
 - Integral absolut semua aksis.
 - Frekuensi puncak tiap aksis i.
- ECG dan BVP:
 - Mean, STD HR.
 - Mean, STD HRV.
 - Jumlah NN50 dan pNN50.
 - TINN.
 - RMShRV.
 - Energi HRV di ULF-UHF.
 - Rasio LF dan HF.
 - Σ frek. komponen di ULF-UHF.
 - Power relatif frek. Komponen.
 - Komponen LF dan HF normalisasi.
- EDA:
 - Mean, STD.
 - Min, maks.
 - Kemiringan dan *dynamic range*
 - Mean, STD dari SCR/SCL.
 - Hubungan SCL dan waktu.

- Jumlah segmen SCR.
- Σ *startle magnitudes and response duration*.
- Area di bawah SCR yang teridentifikasi.
- EMG:
 - Mean, STD.
 - *Dynamic range*.
 - Integral mutlak.
 - Median.
 - Persentil ke-10 dan ke-90.
 - Mean, median, dan *peak* frekuensi.
 - *Energy in seven bands*.
 - Jumlah *peaks*.
 - Mean, STD amplitudo *peak*.
 - Σ dan Σ ternormalisasi dari amplitudo *peaks*.
- Respiratory (RESP):
 - Mean, STD dari durasi hirup (*inhale* [I]) dan hembus (*exhale* [E]).
 - Rasio I/E.
 - *Range* dan volume.
 - *Breath rate*.
 - Durasi respirasi.
- Suhu (TEMP):
 - Mean, STD.
 - Min, Maks.
 - *Dynamic Range*.
 - Kemiringan.

3.5 Pengembangan Model *Machine Learning*

3.5.1 Algoritma Model

Eksperimen akan menguji beberapa algoritma *machine learning* berbasis fitur yang telah terbukti andal pada literatur WESAD oleh Schmidt et al. (2018), yaitu:

- *Random Forest* (RF),
- *Support Vector Machine* (SVM),
- *XGBoost* (XGB), dan

- *k-Nearest Neighbor* (k-NN).

3.5.2 Skema Validasi Model (*Cross-Validation*)

Untuk konsistensi, evaluasi pada dataset WESAD menggunakan metode *n-Fold Cross-Validation*, dimana *n* bernilai 5 (*5-Fold Cross-Validation*) sesuai dengan referensi penelitian yang dilakukan oleh Alkurdi et al. (2025).

3.6 Implementasi Sistem pada Smartwatch (*Deployment*)

Model terbaik yang dilatih pada Skenario 2 dan Skenario 3 akan diekspor ke dalam format model ringan TensorFlow Lite (.tfl) dan diupload ke *smartwatch*.

- Mekanisme Inferensi:

Aplikasi pada *smartwatch* akan mengumpulkan data sensor secara kontinu, tidak ada aktivitas lain pada aplikasi selain pengumpulan data. Data uji yang selesai terkumpulkan kemudian akan diekspor ke komputer untuk dilakukan deteksi *anxiety*. Hal ini dilakukan untuk menghindari membebani kinerja *smartwatch* ketika sedang melakukan pengumpulan data secara terus-menerus, mengingat sumber daya pada *wearables* yang sangat terbatas.

Jika perangkat *smartwatch* tidak memungkinkan alur tersebut karena sumber daya yang terbatas atau hal lainnya, maka inferensi dilakukan di komputer eksternal. *Smartwatch* akan terhubung dengan komputer untuk mengirim data sinyal secara kontinu, data yang terkumpulkan ini kemudian akan disimpan dan diinferensi pada komputer tersebut.

3.7 Metrik Pengujian dan Rencana Analisis Komparasi

3.7.1 Metrik Evaluasi

Kinerja model dievaluasi menggunakan metrik yang sama yang dilakukan pada studi Alkurdi et al. (2025):

- Akurasi (*Accuracy*): Rasio total prediksi benar terhadap keseluruhan sampel.
- *F1-Score*: Nilai rata-rata harmonis antara presisi dan sensitivitas, yang sangat krusial mengingat data kondisi fisiologis kerap mengalami ketidakseimbangan kelas (*class imbalance*).

3.7.2 Rencana Komparasi Hasil

Hasil evaluasi dari kelima skenario akan dirangkum dalam tabel komparasi berikut untuk menguji hipotesis penelitian:

Tabel 3.1 Komparasi Skenario-Skenario Penelitian

Skenario	Sumber data uji	Konfigurasi sensor yang digunakan	Lingkungan	Tujuan
1	WESAD	Seluruh sensor	Laboratorium (sekunder)	Pengukuran Akurasi Referensi (<i>Upper Bound Benchmark</i>)
2	WESAD	Irisan sensor WESAD dan <i>smartwatch</i>	Laboratorium (sekunder)	Menghitung penurunan performa akibat reduksi modalitas sensor
3	WESAD	Sensor paling signifikan (<i>smartwatch</i>)	Laboratorium (sekunder)	Efektivitas reduksi modalitas ke fitur paling dominan
4	Partisipan	Irisan sensor WESAD dan <i>smartwatch</i>	Dunia nyata	Degradasi performa model <i>smartwatch</i> di lingkungan riil vs. Skenario 1 & 2
5	Partisipan	Sensor paling signifikan (<i>smartwatch</i>)	Dunia nyata	Kelayakan model paling minimalis diuji langsung pada dunia nyata

3.8 Lingkungan dan Peralatan Pendukung

Untuk mendukung pelaksanaan penelitian, peralatan yang digunakan mencakup:

3.8.1 Perangkat Keras (*Hardware*):

- Laptop (Prosesor Intel i5-11400H, RAM 16 GB DDR4, GPU RTX 3050) untuk pelatihan model dan pengolahan awal dataset WESAD.
- *Smartwatch* Samsung Galaxy Watch9 atau lainnya yang dilengkapi sensor biosinyal dengan spesifikasi minimal mendukung pengukuran 2 sensor yang terdapat pada dataset WESAD. Minimal 2 sensor yang beririsan diperlukan karena skenario 3 dan 5 tidak akan dapat dilakukan jika hanya memiliki 1 sensor.

3.8.2 Perangkat Lunak (*Software*):

- Sistem Operasi: Windows 11 (komputer) dan Wear OS (*smartwatch*).
- Bahasa Pemrograman: Python 3.0+ untuk analisis data, pemodelan *machine learning*, dan ekstraksi model; Android Studio dengan bahasa pemrograman Kotlin untuk pengembangan dan *deployment* aplikasi pada *smartwatch*.
- *Libraries*: NumPy, Pandas, SciPy, Scikit-learn, BioSPPy, NeuroKit2, XGBoost, dan lainnya yang akan dibutuhkan.
- Instrumen Psikometri: Kuesioner digital State-Trait Anxiety Inventory (STAI Form Y-1) yang telah diterjemahkan ke bahasa Indonesia.

DAFTAR REFERENSI

- Alkurdi, A., He, M., Cerna, J., Clore, J., Sowers, R., Hsiao-Wecksler, E.T. and Hernandez, M.E., 2025. Extending anxiety detection from multimodal wearables in controlled conditions to real-world environments. *Sensors*, 25(4), p. 1241. Tersedia di: <<https://doi.org/10.3390/s25041241>> [Diakses 10 September 2026].
- Allen, J., 2007. Photoplethysmography and its application in clinical physiological measurement. *Physiological Measurement*, 28(3), pp. R1–R39. Tersedia di: <https://doi.org/10.1088/0967-3334/28/3/R01> [Diakses 11 September 2026].
- Amin, R. and Faghih, R.T., 2022. Physiological characterization of electrodermal activity enables scalable near real-time autonomic nervous system activation inference. *PLoS computational biology*, 18(7), p.e1010275. Tersedia di: <<https://doi.org/10.1371/journal.pcbi.1010275>> [Diakses 11 September 2026].
- Alodokter, 2024. *Elektromiografi, ini yang harus Anda ketahui*. [daring] Alodokter. Tersedia di: <<https://www.alodokter.com/elektromiografi-ini-yang-harus-anda-ketahui>> [Diakses 11 September 2026].
- Alodokter, 2026. *Memahami suhu tubuh dan cara mengukurnya*. Ditinjau secara medis oleh dr. Marianti. Tersedia di: <<https://www.alodokter.com/memahami-suhu-tubuh>> [Diakses 11 September 2026].
- Gedam, S. and Paul, S., 2021. A review on mental stress detection using wearable sensors and machine learning techniques. *IEEE Access*, 9, pp. 84045–84066. Tersedia di: <<https://ieeexplore.ieee.org/document/9445082>> [Diakses 11 September 2026].
- Goodfellow, I., Bengio, Y. dan Courville, A., 2016. *Deep learning*. Cambridge: MIT Press. Tersedia di: <<https://www.deeplearningbook.org/>> [Diakses 11 September 2026].
- Gomes, N., Pato, M., Lourenço, A.R. and Datia, N., 2023. A survey on wearable sensors for mental health monitoring. *Sensors*, 23(3), art. no. 1330. Tersedia di: <<https://www.mdpi.com/1424-8220/23/3/1330>> [Diakses 31 Agustus 2026].
- Haritha, H., Negi, S., Menon, R.S., Kumar, A.A. and Kumar, C.S., 2017. Automating anxiety detection using respiratory signal analysis. In: *2017 IEEE Region 10 Symposium (TENSYP)*. Cochin, India, 14–16 Juli 2017. Piscataway: IEEE. Tersedia di: <<https://ieeexplore.ieee.org/document/8069995>> [Diakses 11 September 2026].
- He, M., Alkurdi, A., Clore, J.L., Sowers, R.B., Hsiao-Wecksler, E.T. and Hernandez, M.E., 2025. *Review of ML approaches in anxiety detection from in-lab to in-*

- the-wild*. [preprint] Preprints.org. Tersedia di: <<https://www.preprints.org/manuscript/202507.2265>> [Diakses 11 September 2026].
- Kirschbaum, C., Pirke, K.M. and Hellhammer, D.H., 1993. The 'Trier social stress test'--a tool for investigating psychobiological stress responses in a laboratory setting. *Neuropsychobiology*, 28(1–2), pp. 76–81. Tersedia di: <<https://doi.org/10.1159/000119004>> [Diakses 11 September 2026].
- McGinnis, R.S., McGinnis, E.W., Hruschak, J., Lopez-Duran, N.L., Fitzgerald, K. dan Rosenblum, K.L., 2018. Wearable sensors and machine learning diagnose anxiety and depression in young children. Dalam: *2018 IEEE EMBS International Conference on Biomedical & Health Informatics (BHI)*. Las Vegas, NV, Amerika Serikat, 4–7 Maret 2018. Piscataway: IEEE, hlm. 398–401. Tersedia di: <<https://doi.org/10.1109/BHI.2018.8333455>> [Diakses 11 September 2026].
- Muhammad, F. and Al-Ahmadi, S., 2022. Human state anxiety classification framework using EEG signals in response to exposure therapy. *PLOS ONE*, 17(3), p. e0265679. Tersedia di: <<https://doi.org/10.1371/journal.pone.0265679>> [Diakses 11 September 2026].
- National Library of Medicine, 2026. *Electrocardiogram*. [daring] Tersedia di: <<https://www.medlineplus.gov/lab-tests/electrocardiogram/>> [Diakses 11 September 2026].
- Schmidt, P., Reiss, A., Duerichen, R., Marberger, C. dan Van Laerhoven, K., 2018. Introducing WESAD, a multimodal dataset for wearable stress and affect detection. Dalam: *ICMI '18: Proceedings of the 2018 International Conference on Multimodal Interaction*. Boulder, CO, USA, 16–20 Oktober 2018. New York: ACM, hlm. 400–408. Tersedia di: <<https://doi.org/10.1145/3242969.3242985>> [Diakses 10 September 2026].
- Spielberger, C.D., 1966. Theory and research on anxiety. Tersedia di: <<https://www.semanticscholar.org/paper/Theory-and-research-on-anxiety-Spielberger/a179615d474f07e06cc6900c001f834278077a4d>> [Diakses 2 September 2026].
- Spielberger, C.D., Gorsuch, R.L., Lushene, R.E., Vagg, P.R. and Jacobs, G.A., 1983. Manual for the State-Trait Anxiety Inventory (Form Y1 – Y2). *California: Consulting Psychologists Press*. Tersedia di: <https://www.researchgate.net/publication/235361542_Manual_for_the_State-Trait_Anxiety_Inventory_Form_Y1_-_Y2> [Diakses 10 September 2026].
- Stroop, J.R., 1935. Studies of interference in serial verbal reactions. *Journal of Experimental Psychology: General*, 18, pp. 643–662. Tersedia di: <<https://doi.org/10.1037/h0054651>> [Diakses 11 September 2026].

- Tayarani-N., M.-H. dan Shahid, S.I., 2025. Detecting anxiety via machine learning algorithms: A literature review. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 9(4), hlm. 2634–2657. Tersedia di: <<https://doi.org/10.1109/TETCI.2025.3543307>> [Diakses 10 September 2026].
- Vytal, K., Cornwell, B., Arkin, N. and Grillon, C., 2012. Describing the interplay between anxiety and cognition: from impaired performance under low cognitive load to reduced anxiety under high load. *Psychophysiology*, 49(6), pp. 842–852. Tersedia di: <<https://pmc.ncbi.nlm.nih.gov/articles/PMC3345059/>> [Diakses 10 September 2026].
- Wikipedia, 2026. *AdaBoost*. [daring] Tersedia di: <<https://en.wikipedia.org/wiki/AdaBoost>> [Diakses 11 September 2026].
- Wikipedia, 2026. *Decision tree learning*. [daring] Tersedia di: <https://en.wikipedia.org/wiki/Decision_tree_learning> [Diakses 11 September 2026].
- Wikipedia, 2026. *k-nearest neighbors algorithm*. [daring] Tersedia di: <https://en.wikipedia.org/wiki/K-nearest_neighbors_algorithm> [Diakses 11 September 2026].
- Wikipedia, 2026. *Linear discriminant analysis*. [daring] Tersedia di: <https://en.wikipedia.org/wiki/Linear_discriminant_analysis> [Diakses 11 September 2026].
- Wikipedia, 2026. *Random forest*. [daring] Tersedia di: <https://en.wikipedia.org/wiki/Random_forest> [Diakses 11 September 2026].
- Wikipedia, 2026. *Support vector machine*. [daring] Tersedia di: <https://en.wikipedia.org/wiki/Support_vector_machine> [Diakses 11 September 2026].
- Wikipedia, 2026. *XGBoost*. [daring] Tersedia di: <<https://en.wikipedia.org/wiki/XGBoost>> [Diakses 11 September 2026].

LAMPIRAN A KUESIONER EVALUASI METRIK STAI

A.1 Kuesioner Evaluasi Diri STAI Form Y-1

SELF-EVALUATION QUESTIONNAIRE STAI Form Y-1

Please provide the following information:

Name _____ Date _____ S _____

Age _____ Gender (Circle) M F T _____

DIRECTIONS:

A number of statements which people have used to describe themselves are given below. Read each statement and then blacken the appropriate circle to the right of the statement to indicate how you feel *right now*, that is, at *this moment*. There are no right or wrong answers. Do not spend too much time on any one statement but give the answer which seems to describe your present feelings best.

NOT AT ALL
SOMEWHAT
MODERATELY SO
VERY MUCH SO

- | | | | | |
|--|---|---|---|---|
| 1. I feel calm..... | 1 | 2 | 3 | 4 |
| 2. I feel secure..... | 1 | 2 | 3 | 4 |
| 3. I am tense | 1 | 2 | 3 | 4 |
| 4. I feel strained | 1 | 2 | 3 | 4 |
| 5. I feel at ease | 1 | 2 | 3 | 4 |
| 6. I feel upset..... | 1 | 2 | 3 | 4 |
| 7. I am presently worrying over possible misfortunes | 1 | 2 | 3 | 4 |
| 8. I feel satisfied..... | 1 | 2 | 3 | 4 |
| 9. I feel frightened..... | 1 | 2 | 3 | 4 |
| 10. I feel comfortable..... | 1 | 2 | 3 | 4 |
| 11. I feel self-confident..... | 1 | 2 | 3 | 4 |
| 12. I feel nervous | 1 | 2 | 3 | 4 |
| 13. I am jittery..... | 1 | 2 | 3 | 4 |
| 14. I feel indecisive..... | 1 | 2 | 3 | 4 |
| 15. I am relaxed..... | 1 | 2 | 3 | 4 |
| 16. I feel content..... | 1 | 2 | 3 | 4 |
| 17. I am worried..... | 1 | 2 | 3 | 4 |
| 18. I feel confused..... | 1 | 2 | 3 | 4 |
| 19. I feel steady..... | 1 | 2 | 3 | 4 |
| 20. I feel pleasant..... | 1 | 2 | 3 | 4 |